

CSF620

MODUL BIG DATA

SESI 2

ANALISIS BIG DATA (BAGIAN I)

DISUSUN OLEH:

ARIEF ICHWANI, ST, MT

ANALISIS BIG DATA (BAGIAN I)

A. Pengertian Analisis

Pengertian Analisis adalah aktivitas yang memuat sejumlah kegiatan seperti mengurai, membedakan, memilah sesuatu untuk digolongkan dan dikelompokkan kembali menurut kriteria tertentu kemudian dicari kaitannya dan ditafsir maknanya. Dalam defnisi lain, Analisis adalah proses menyadari sesuatu dengan teliti dan hati-hati, atau menggunakan data dan metode statistik untuk memahami atau menjelaskan hal tersebut. Defnisi ini merupakan rumusan umum tentang analisis.

Analisis adalah istilah luas yang mencakup proses, teknologi, kerangka kerja, dan algoritma untuk mengekstrak wawasan yang bermakna dari data. Data Mentah itu sendiri tidak memiliki arti sampai dikontekstualisasikan dan diolah menjadi informasi yang berguna. Analisis adalah proses mengekstraksi dan membuat informasi dari raw data dengan menyaring, memproses, mengkategorikan, memadatkan, dan mengontekstualisasikan data. Informasi yang diperoleh ini kemudian diatur dan disusun untuk pengetahuan tentang sistem dan / atau penggunaannya, lingkungannya, dan operasi serta kemajuannya menuju tujuannya, sehingga membuat sistem lebih cerdas dan lebih efisien.


Pilihan teknologi, algoritma, dan kerangka kerja untuk analisis didorong oleh tujuan analisis dari aplikasi. Tujuan dari tugas analisis antara lain :

- a) untuk memprediksi sesuatu (misalnya, apakah transaksi itu tidak akan terjadi, apakah akan terjadi pada hari tertentu, atau apakah tumor itu jinak atau ganas),
- b) untuk menemukan pola dalam data (misalnya, menemukan pola urutan 10 hari terdingin dalam setahun, menemukan halaman mana yang paling banyak dikunjungi di situs web tertentu, atau menemukan selebriti yang paling banyak ditelusuri pada tahun tertentu),
- c) menemukan hubungan dalam data (misalnya, menemukan artikel berita yang serupa, menemukan pasien serupa dalam sistem catatan kesehatan elektronik, menemukan produk terkait di situs *web e-Commerce*, menemukan gambar serupa, atau menemukan korelasi antara item berita dan harga saham).

National Research Council telah melakukan karakterisasi tugas komputasi untuk analisis Big Data-yang masif (disebut tujuh "raksasa"). Tugas komputasi ini meliputi: (1) Statistik Basis, (2) Masalah Umum N-Body, (3) Komputasi Aljabar Linear, (4) Komputasi Grafi-Teoretik, (5) Optimasi, (6) Integrasi dan (7) Masalah Alignment. Karakterisasi tugas

komputasi ini bertujuan untuk memberikan taksonomi tugas yang telah terbukti berguna dalam analisis data dan mengelompokkan mereka secara kasar menurut struktur matematika dan strategi komputasi.

Berikut pemetaan antara jenis analisis dari tujuh komputasi super besar. Gambar 1.1 menunjukkan pemetaan antara jenis analisis dan tujuh komputasi "raksasa".



Gambar 1. Pemetaan antara Jenis Analisis dan Tujuh Raksasa Komputasi.

1. Analisis Deskriptif

Analisis deskriptif dapat digunakan untuk mengolah data kuantitatif. Cara ini dilakukan untuk melihat performa data di masa lalu agar dapat mengambil kesimpulan dari hal tersebut. Metode ini mengedepankan deskripsi yang memungkinkan kamu untuk belajar dari hal lalu. Biasanya, metode analisis jenis ini diaplikasikan pada data dengan volume yang sangat besar seperti data sensus misalnya. Analisis deskriptif bertujuan untuk menjawab "Apa yang terjadi?" Sebagian besar analisis yang dilakukan saat ini adalah analisis berbasis deskriptif melalui penggunaan fungsi statistik seperti hitungan, maksimum, minimum, mean, top-N, dan persentase. Statistik ini membantu dalam mendeskripsikan pola dalam data dan menyajikan data dalam bentuk ringkasan. Misalnya, menghitung jumlah total "suka" untuk pos tertentu, menghitung rata-rata curah hujan bulanan atau menemukan jumlah orang yang mengunjungi sebuah situs web perbulannya. Analisis deskriptif berguna untuk meringkas data. Di Bab-3, kami menjelaskan implementasi berbagai pola MapReduce untuk analisis deskriptif (seperti fungsi Count, Max/Min, Average, Distinct, dan Top-N).

Di antara tujuh tugas komputasi seperti yang ditunjukkan pada Gambar 1, tugas seperti Statistik Dasar dan Perhitungan Aljabar Linier dapat digunakan untuk analisis deskriptif.

2. Analisis Diagnostik

Analisis diagnostik terdiri dari analisis data lalu lintas dan data tentang berbagai alasan mengapa sebuah kejadian tertentu terjadi. Analisis diagnostik bertujuan untuk menjawab "Mengapa sesuatu itu terjadi?" Mari kita pertimbangkan contoh sistem yang mengumpulkan dan menganalisis data sensor dari mesin untuk memantau kesehatan dan memprediksi kegagalan. Meskipun analisis deskriptif dapat berguna untuk meringkas data dengan menghitung berbagai statistik (seperti mean, Count, Max/Min, Average, Distinct, dan Top-N), analisis diagnostik dapat memberikan lebih banyak wawasan tentang mengapa kesalahan tertentu telah terjadi berdasarkan pola dalam data sensor untuk kesalahan sebelumnya. Di antara tujuh tugas komputasi, tugas komputasi seperti Perhitungan Aljabar Linier, Masalah Umum N-Body, dan Komputasi Grafi-teoretis dapat digunakan untuk analisis diagnostik.

3. Analisis Prediktif

Analisis prediktif terdiri dari memprediksi terjadinya suatu kejadian atau kemungkinan hasil dari suatu peristiwa atau memperkirakan nilai masa depan menggunakan model prediksi. Analisis prediktif bertujuan untuk menjawab "Apa yang mungkin terjadi?" Misalnya, analisis prediktif dapat digunakan untuk memprediksi kapan kesalahan akan terjadi pada mesin, memprediksi apakah tumor jinak atau ganas, memprediksi terjadinya keadaan darurat alami (misalnya, peristiwa kebakaran hutan atau banjir bandang) atau memperkirakan tingkat polusi. Analisis Prediktif dilakukan menggunakan model prediktif yang dukung dengan data yang tersedia. Model-model ini mempelajari pola dan tren dari data yang ada dan memprediksi terjadinya suatu kejadian atau kemungkinan hasil dari suatu kejadian (model klasifikasi) atau angka perkiraan (model regresi). Akurasi model prediksi bergantung pada kualitas dan volume data yang ada yang tersedia untuk memperkuat model, sehingga semua pola dan tren dalam data yang ada dapat dipelajari secara akurat. Sebelum model digunakan untuk prediksi, model harus divalidasi dengan data yang ada. Pendekatan tipikal yang diadopsi saat mengembangkan model prediksi adalah dengan membagi data yang ada menjadi kumpulan data pelatihan dan pengujian

(misalnya 75% data digunakan untuk pelatihan dan 25% data digunakan untuk menguji model prediksi). Dalam Bab-11, kami menyediakan implementasi berbagai algoritme untuk analisis prediktif (termasuk algoritme pengelompokan, klasifikasi, dan regresi) menggunakan kerangka kerja seperti Spark MLlib dan H2O. Di antara tujuh tugas komputasi, tugas-tugas seperti Perhitungan Aljabar Linear, Masalah Umum N-Body, Komputasi Grafi-teoretis, Masalah Integrasi dan Alignment dapat digunakan untuk analisis prediktif.

4. Analisis Preskriptif

Sementara analisis prediktif menggunakan model prediksi untuk memprediksi kemungkinan hasil dari suatu peristiwa, analisis preskriptif menggunakan beberapa model prediksi untuk memprediksi berbagai hasil dan tindakan terbaik untuk setiap hasil. Analisis preskriptif bertujuan untuk menjawab "Apa yang dapat kita lakukan untuk mewujudkannya?" Analisis Preskriptif dapat memprediksi hasil yang mungkin berdasarkan pilihan tindakan saat ini. Kami dapat mempertimbangkan analisis preskriptif sebagai jenis analisis yang menggunakan model prediksi berbeda untuk input berbeda. Analisis preskriptif menentukan tindakan atau opsi terbaik untuk diikuti dari opsi yang tersedia. Misalnya, analisis preskriptif dapat digunakan untuk menggambarkan pengobatan terbaik untuk pengobatan bagi pasien berdasarkan hasil dari berbagai obat untuk pasien serupa. Contoh lain dari analisis preskriptif akan menyarankan paket data seluler terbaik untuk pelanggan berdasarkan pola penjelajahan pelanggan. Di antara tujuh tugas komputasi, tugas-tugas seperti Masalah Umum N-Body, Perhitungan Graphtheoretic, Masalah Optimasi dan Alignment dapat digunakan untuk analisis preskriptif.

B. Alur Analisis Big Data

Aliran generik untuk analisis Big Data, yang merinci langkah-langkah yang terlibat dalam penerapan aplikasi analisis khas dan opsi yang tersedia di setiap langkah, disajikan. Gambar 1 menunjukkan aliran analisis dengan berbagai langkah. Untuk aplikasi, memilih opsi untuk setiap langkah dalam aliran analisis dapat membantu dalam menentukan alat dan kerangka kerja yang tepat untuk melakukan analisis.

a) Pengumpulan data

Pengumpulan data adalah langkah pertama untuk aplikasi analisis apa pun. Sebelum data dapat dianalisis, data harus dikumpulkan dan diserap ke dalam Big Data Stack. Pilihan alat dan kerangka kerja untuk pengumpulan data bergantung pada sumber data dan jenis data yang diserap. Untuk pengumpulan data, berbagai jenis konektor dapat digunakan seperti kerangka perpesanan langganan-publikasi, antrean perpesanan, konektor sumbersink, konektor database, dan konektor kustom. Konektor bisa diimplementasikan dengan berbagai cara seperti Konektor Berbasis REST, Konektor berbasis WebSocket, Konektor berbasis MQTT, Amazon IoT, azure IoT Hub .


b) Persiapan data

Data sering kali kotor dan dapat memiliki berbagai masalah yang harus diselesaikan sebelum data dapat diproses, seperti catatan rusak, nilai yang hilang, duplikat, singkatan yang tidak konsisten, unit yang tidak konsisten, kesalahan ketik, ejaan yang salah, dan format yang salah. Langkah persiapan data melibatkan berbagai tugas seperti pembersihan data, perselisihan atau munging data, de-duplikasi, normalisasi, pengambilan sampel dan pemfiteran. Pembersihan data mendeteksi dan menyelesaikan masalah seperti catatan rusak, catatan dengan nilai yang hilang, catatan dengan format yang buruk, misalnya. Perselisihan data atau munging berkaitan dengan mengubah data dari satu format mentah ke format lainnya. Sebagai contoh, ketika kita mengumpulkan *record* sebagai file teks mentah dari sumber yang berbeda, kita mungkin menemukan ketidakkonsistenan pada pemisah field yang digunakan pada file yang berbeda.

Beberapa file mungkin menggunakan koma sebagai pemisah bidang, yang lain mungkin menggunakan tab sebagai pemisah bidang. Perselisihan data menyelesaikan ketidakkonsistenan ini dengan mengurai raw data dari sumber yang berbeda dan mengubahnya menjadi satu format yang konsisten. Normalisasi diperlukan bila data dari sumber berbeda menggunakan satuan atau skala yang berbeda atau memiliki singkatan yang berbeda untuk hal yang sama. Misalnya, data cuaca yang dilaporkan oleh beberapa stasiun mungkin berisi suhu dalam skala Celcius sedangkan data dari stasiun lain mungkin menggunakan skala Fahrenheit. Pemfiteran dan pengambilan sampel mungkin berguna ketika kita ingin memproses hanya data yang memenuhi aturan tertentu. Pemfiteran juga dapat berguna untuk menolak catatan buruk dengan nilai yang salah atau di luar kisaran

c) Tipe analisis

Langkah selanjutnya dalam aliran analisis adalah menentukan jenis analisis untuk aplikasi. Pada Gambar 1 kami telah membuat daftar berbagai opsi untuk jenis analisis dan algoritma populer untuk setiap jenis analisis. Berikut implementasi algoritma menggunakan berbagai kerangka dan alat Big Data.



Gambar 2 . Arus Analisis Big Data.

Dengan jenis analisis yang dipilih untuk suatu aplikasi, langkah selanjutnya adalah menentukan mode analisis, yang dapat berupa batch, real-time, atau interaktif. Pilihan mode tergantung pada persyaratan aplikasi. Jika aplikasi yang digunakan meminta hasil untuk diperbarui setelah interval waktu yang singkat (katakanlah setiap beberapa detik), maka mode analisis real-time dipilih. Namun jika aplikasi tersebut hanya membutuhkan hasil yang akan dibuat dan diperbarui pada skala waktu yang lebih besar (katakanlah harian atau bulanan), maka mode batch dapat digunakan. Jika aplikasi menuntut fleksibilitas untuk meminta data sesuai permintaan, maka mode interaktif berguna. Setelah membuat pilihan jenis analisis dan mode analisis, selanjutnya dapat menentukan pola pemrosesan data yang dapat digunakan. Misalnya, untuk statistik dasar sebagai jenis analisis dan mode analisis batch, MapReduce bisa menjadi pilihan yang baik. Sedangkan untuk analisis regresi sebagai jenis analisis dan mode analisis real-time (memprediksi nilai secara realtime), pola Stream Processing merupakan

pilihan yang baik. Pilihan jenis analisis, mode analisis, dan pola pemrosesan data dapat membantu dalam memilih alat dan kerangka kerja yang tepat untuk analisis data.

d) Visualisasi

Pilihan alat visualisasi, database penyajian, dan kerangka kerja web dipengaruhi oleh persyaratan aplikasi. Visualisasi bisa statis, dinamis atau interaktif. Visualisasi statis digunakan saat memiliki hasil analisis yang disimpan dalam database penyajian dan hanya ingin menampilkan hasilnya. Namun, jika aplikasi meminta hasil diperbarui secara berkala, maka dibutuhkan visualisasi dinamis (dengan *widget*, *plot*, atau pengukur langsung). Jika ingin aplikasi yang digunakan menerima masukan dari pengguna dan menampilkan hasilnya, maka dibutuhkan adanya visualisasi interaktif.

C. Big Data Stack

Meskipun kerangka kerja Hadoop telah menjadi salah satu kerangka kerja paling populer untuk analisis Big Data, ada beberapa jenis tugas komputasi yang tidak berfungsi dengan baik oleh Hadoop. Dengan bantuan pemetaan antara jenis analisis dan komputasi "raksasa" seperti yang ditunjukkan pada Gambar 1, kami akan mengidentifikasi kasus di mana Hadoop bekerja dan di mana tidak, dan menjelaskan motivasi untuk memiliki Big Data Stack yang dapat digunakan untuk berbagai jenis analisis dan tugas komputasi.

Hadoop adalah kerangka kerja sumber terbuka untuk pemrosesan batch terdistribusi dari data skala besar menggunakan model pemrograman Map Reduce. Model pemrograman Map Reduce berguna untuk aplikasi di mana data yang terlibat sangat besar sehingga tidak akan muat pada satu mesin. Dalam aplikasi semacam itu, data biasanya disimpan pada sistem file terdistribusi (seperti Hadoop Distributed File System-HDFS). Program MapReduce memanfaatkan lokalitas data dan pemrosesan data berlangsung di node tempat data berada. Dengan kata lain, penghitungan dipindahkan ke tempat data berada, sebagai kebalikan dari cara tradisional memindahkan data dari tempatnya berada ke tempat penghitungan selesai. MapReduce paling cocok untuk analisis deskriptif dan tugas komputasi statistik dasar karena operasi yang terlibat dapat dilakukan secara paralel (misalnya, menghitung hitungan, rata-rata, maks / min, distinct, top-N, filter, dan join).

Banyak dari operasi ini diselesaikan dengan satu pekerjaan MapReduce. Untuk tugas yang lebih kompleks, beberapa pekerjaan MapReduce dapat digabungkan bersama. Namun, ketika komputasi bersifat iteratif, di mana tugas MapReduce harus dijalankan berulang kali, MapReduce mengalami penurunan kinerja karena overhead yang terlibat dalam pengambilan data dari HDFS di setiap iterasi.

Untuk jenis analisis dan tugas komputasi lainnya, ada kerangka kerja alternatif lain yang akan kita bahas sebagai bagian dari Big Data Stack. Dalam Bab ini, kami mengusulkan dan menjelaskan Big Data Stack yang terdiri dari kerangka kerja Big Data yang terbukti dan bersumber terbuka yang membentuk dasar buku ini. Gambar 3 menunjukkan Big Data Stack dengan nomor Bab yang disorot untuk berbagai blok dalam tumpukan. Bab berikutnya dalam buku ini menjelaskan blok-blok ini secara rinci bersama dengan contoh-contoh langsung dan studi kasus. Kami telah menggunakan Python sebagai bahasa pemrograman utama untuk contoh dan studi kasus di seluruh buku ini. Mari kita lihat setiap blok satu per satu:

1. Sumber Raw Data

Dalam aplikasi atau platform analisis Big Data apa pun, sebelum data diproses dan dianalisis, data harus diambil dari sumber raw data ke dalam kerangka dan sistem Big Data. Beberapa contoh sumber Big Raw data meliputi:

- Log: Log yang dihasilkan oleh aplikasi web dan server yang dapat digunakan untuk pemantauan kinerja
- Data Transaksional: Data transaksional yang dihasilkan oleh aplikasi seperti e-Commerce, Perbankan dan Keuangan
- Media Sosial: Data yang dihasilkan oleh platform media sosial
- Database: Data terstruktur yang berada di database relasional
- Data Sensor: Data sensor yang dihasilkan oleh sistem Internet of Things (IoT)
- Data Clickstream: Data clickstream yang dihasilkan oleh aplikasi web yang dapat digunakan untuk menganalisis pola penjelajahan pengguna
- Data Pengawasan: Data sensor, gambar dan video yang dihasilkan oleh sistem pengawasan.
- Data Perawatan Kesehatan: Data perawatan kesehatan yang dihasilkan oleh Electronic Health Record (EHR) dan aplikasi perawatan kesehatan lainnya

- **Data Jaringan:** Data jaringan yang dihasilkan oleh perangkat jaringan seperti router dan firewall

2. Konektor Akses Data

Konektor Akses Data mencakup alat dan kerangka kerja untuk mengumpulkan dan menyerap data dari berbagai sumber ke dalam kerangka penyimpanan Big Data dan kerangka kerja analisis. Pilihan konektor data ditentukan oleh jenis sumber data. Mari kita lihat beberapa konektor data dan kerangka kerja yang dapat digunakan untuk mengumpulkan dan menyerap data. Konektor ini dapat mencakup koneksi kabel dan nirkabel.

- ***Publish-Subscribe Messaging***

Publish-Subscribe adalah model komunikasi yang melibatkan penerbit, broker dan konsumen. Penerbit adalah sumber data. Penerbit mengirimkan data ke topik yang dikelola oleh broker. Kerangka kerja perpesanan langganan-terbitkan seperti Apache Kafka dan Amazon Kinesis dijelaskan di Bab-5.

- **Konektor Source-Sink**

Konektor Source-Sink memungkinkan pengumpulan, penggabungan, dan pemindahan data secara efisien dari berbagai sumber (seperti log server, database, media sosial, data sensor streaming dari perangkat Internet of Things dan sumber lainnya) ke dalam penyimpanan data terpusat (seperti sebagai sistem terdistribusi). Apache Flume yang merupakan kerangka kerja untuk mengumpulkan data dari berbagai sumber. Flume menggunakan model aliran data yang terdiri dari source, channel, dan sink.

- **Konektor Database**


Konektor Database dapat digunakan untuk mengimpor data dari sistem manajemen Database relasional ke dalam penyimpanan Big Data dan kerangka kerja analisis untuk analisis. Di Bab-5 kami telah menjelaskan Apache Sqoop, yang merupakan alat yang memungkinkan mengimpor data dari database relasional.

- **Antrian Pesan**

Antrian pesan berguna untuk pesan push-pull dimana produsen mendorong data ke antrian dan konsumen menarik data dari antrian. Produsen dan konsumen tidak perlu saling waspada. antrian perpesanan seperti RabbitMQ, ZeroMQ, RestMQ, dan Amazon SQS.

- **Konektor Khusus**

Konektor khusus dapat dibuat berdasarkan sumber data dan persyaratan pengumpulan data. Beberapa contoh konektor kustom meliputi: konektor kustom untuk mengumpulkan data dari jejaring sosial, konektor kustom untuk database NoSQL, dan konektor untuk Internet of Things (IoT). Konektor kustom berdasarkan REST, WebSocket, dan MQTT. Konektor IoT seperti AWS IoT dan Azure IoT Hub.



Gambar 3. *Big Data Stack*

3. Data Storage (Penyimpanan Data)

Blok penyimpanan data dalam Big Data Stack mencakup sistem file terdistribusi dan database non-relasional (NoSQL), yang menyimpan data yang dikumpulkan dari sumber raw data menggunakan konektor akses data. Di sesi materi selanjutnya akan dijelaskan Hadoop Distributed File System (HDFS), sistem file terdistribusi yang berjalan pada cluster besar dan menyediakan akses throughput tinggi ke data.

Dengan data yang disimpan di HDFS, data dapat dianalisis dengan berbagai kerangka kerja

analisis Big Data yang dibangun di atas HDFS. Untuk aplikasi analisis tertentu, sebaiknya

menyimpan data dalam database NoSQL seperti HBase. HBase adalah database terukur,

non-relasional, terdistribusi, berorientasi kolom yang menyediakan penyimpanan data terstruktur untuk tabel besar.

4. Analisis Batch

Blok analisis batch dalam Big Data Stack mencakup berbagai kerangka kerja yang memungkinkan analisis data dalam batch. Ini termasuk yang berikut:

- **Hadoop-MapReduce**

Hadoop adalah kerangka kerja untuk pemrosesan batch Big Data yang terdistribusi. Model pemrograman MapReduce digunakan untuk mengembangkan pekerjaan analisis batch yang dijalankan di cluster Hadoop.

- **Pig**

Pig adalah bahasa pemrosesan data tingkat tinggi yang memudahkan pengembang untuk menulis skrip analisis data yang diterjemahkan ke dalam program MapReduce oleh penyusun Pig.

- **Oozie**

Oozie adalah sistem Scheduler aliran kerja yang memungkinkan pengelolaan pekerjaan Hadoop. Dengan Oozie, Anda dapat membuat alur kerja yang kumpulan

- **Spark**

Apache Spark adalah kerangka kerja komputasi cluster open source untuk analisis data. Spark menyertakan berbagai alat tingkat tinggi untuk analisis data seperti Streaming Spark untuk pekerjaan streaming, Spark SQL untuk analisis data terstruktur, perpustakaan pembelajaran mesin MLlib untuk Spark, dan GraphX untuk pemrosesan grafi.

- **Solr**

Apache Solr adalah kerangka kerja sumber terbuka dan skalabel untuk mencari data.

- **Pembelajaran Mesin**

Di sesi selanjutnya akan dijelaskan berbagai algoritme pembelajaran mesin dengan contoh-contoh yang menggunakan kerangka kerja Spark MLlib dan H2O. Spark MLlib adalah

pustaka pembelajaran mesin Spark yang menyediakan implementasi berbagai algoritma pembelajaran mesin. H2O adalah kerangka kerja analisis prediktif open source yang menyediakan implementasi berbagai algoritma pembelajaran mesin.

5. Analisis Real-time

Blok analisis real-time mencakup kerangka kerja Apache Storm dan Spark Streaming. Kerangka kerja ini dijelaskan secara rinci di Bab-8. Apache Storm adalah kerangka kerja untuk komputasi real-time terdistribusi dan toleran terhadap kesalahan. Storm dapat digunakan untuk pemrosesan aliran data secara real-time. Storm dapat menggunakan data dari berbagai sumber seperti kerangka perpesanan langganan-publikasi (seperti Kafka atau Kinesis), antrean perpesanan (seperti RabbitMQ atau ZeroMQ), dan konektor khusus lainnya.

Spark Streaming adalah komponen Spark yang memungkinkan analisis data streaming seperti data sensor, data aliran klik, log server web, misalnya. Data streaming diserap dan dianalisis dalam mikro-batch.

6. Kueri Interaktif

Sistem kueri interaktif memungkinkan pengguna untuk membuat kueri data dengan menulis pernyataan dalam bahasa mirip SQL.

- **SparkSQL**

Spark SQL adalah komponen Spark yang memungkinkan pembuatan kueri interaktif.

Spark SQL berguna untuk membuat kueri data terstruktur dan semi-terstruktur menggunakan kueri seperti SQL.

- **Hive**

Apache Hive adalah kerangka kerja data warehousing yang dibangun di atas Hadoop.

Hive menyediakan bahasa kueri seperti SQL yang disebut Hive Query Language, untuk membuat kueri data yang berada di HDFS.

- **Amazon Redshift**

Amazon Redshift adalah layanan gudang data terkelola skala besar dan cepat. Redshift mengkhususkan diri dalam menangani kueri pada kumpulan data dengan ukuran hingga satu mapbyte atau lebih yang memparalelkan kueri SQL di semua sumber daya di kluster Redshift.

- **Google BigQuery**

Google BigQuery adalah layanan untuk menanyakan dataset yang sangat besar. BigQuery memungkinkan pembuatan kueri dataset menggunakan kueri seperti SQL.

7. Ukuran Database, Web & Kerangka Visualisasi

Sementara berbagai blok analisis memproses dan menganalisis data, hasilnya disimpan dalam database penyajian untuk tugas presentasi dan visualisasi selanjutnya. Penyajian Database ini memungkinkan data yang dianalisis untuk ditanyakan dan disajikan dalam aplikasi web.

- **MySQL**

MySQL adalah salah satu Relational Database Management System (RDBMS) yang paling banyak digunakan dan merupakan pilihan yang baik untuk digunakan sebagai penyajian database untuk aplikasi analisis data terstruktur.

- **Amazon DynamoDB**

Amazon DynamoDB adalah layanan database NoSQL yang dikelola sepenuhnya, dapat diskalakan, dan berperforma tinggi dari Amazon. DynamoDB adalah pilihan yang sangat baik untuk database penyajian untuk aplikasi analisis data karena memungkinkan penyimpanan dan pengambilan data dalam jumlah berapa pun dan kemampuan untuk menaikkan atau menurunkan throughput yang disediakan.

- **Cassandra**

Apache Cassandra atau yang lebih dikenal dengan Cassandra adalah salah satu produk open source untuk manajemen database yang didistribusikan oleh Apache yang sangat scalable (dapat diukur) dan dirancang untuk mengelola data terstruktur yang berkapasitas sangat besar (Big Data) yang tersebar di banyak server. Cassandra merupakan salah satu implementasi dari NoSQL (Not Only SQL) seperti mongoDB. NoSQL merupakan konsep penyimpanan database dinamis yang tidak

terikat pada relasi-relasi tabel yang kaku seperti RDBMS. Selain lebih scalable, NoSQL juga memiliki performa pengaksesan yang lebih cepat.

- **MongoDB**

MongoDB adalah sistem database non-relasional yang berorientasi pada dokumen. MongoDB adalah database yang kuat, fleksibel, dan sangat dapat diskalakan yang dirancang untuk aplikasi web dan merupakan pilihan yang baik untuk database penyajian untuk aplikasi analisis data.

Di sesi selanjutnya dijelaskan Django, yang merupakan kerangka aplikasi web sumber terbuka untuk mengembangkan aplikasi web dengan Python. Django didasarkan pada arsitektur Model-Template-View dan menyediakan pemisahan model data dari aturan bisnis dan interface pengguna. Meskipun aplikasi web dapat berguna untuk menyajikan hasil, alat dan kerangka kerja visualisasi khusus dapat membantu dalam memahami data, dan hasil analisis dengan cepat dan mudah. Alat dan kerangka visualisasi berikut:

- **Lightning**

Lightning adalah kerangka kerja untuk membuat visualisasi interaktif berbasis web.

- **Pygal**

Pustaka Python Pygal adalah pustaka diagram yang mudah digunakan yang mendukung diagram dari berbagai jenis.

- **Seaborn**

Seaborn adalah pustaka visualisasi Python untuk merencanakan plot statistik yang menarik.

D. Memetakan Alur Analisis Tumpukan Data dalam Big Data (Big Data Stack)

Untuk aplikasi big data apa pun, setelah kami menemukan aliran analisis, langkah selanjutnya adalah memetakan aliran analisis ke alat dan kerangka kerja tertentu dalam Big Data Stack. Bagian ini memberikan beberapa pedoman dalam memetakan aliran analisis ke Big Data Stack. Untuk tugas pengumpulan data, pilihan alat atau kerangka kerja tertentu bergantung pada jenis sumber data (seperti file log, mesin yang menghasilkan data sensor, umpan media sosial, catatan dalam database relasional,

misalnya) dan karakteristik data. Jika data akan diserap secara massal (seperti file log), maka sumber sink seperti Apache Flume dapat digunakan. Namun, jika data berkecepatan tinggi akan diserap secara real-time, maka kerangka kerja perpesanan langganan-terbitkan seperti Apache Kafka atau Amazon Kinesis dapat digunakan. Untuk menyerap data dari database relasional, kerangka kerja seperti Apache Sqoop dapat digunakan. Konektor khusus dapat dibuat berdasarkan HTTP / REST, WebSocket atau MQTT, jika solusi lain tidak berfungsi dengan baik untuk aplikasi atau ada kendala tambahan. Misalnya, perangkat IoT yang menghasilkan data sensor mungkin memiliki sumber daya dan daya yang terbatas, dalam hal ini protokol komunikasi ringan seperti MQTT dapat dipilih dan konektor kustom berbasis MQTT dapat digunakan.

Untuk pembersihan dan transformasi data, alat seperti Open Refi dan Stanford Data Wrangler dapat digunakan. Alat ini mendukung berbagai format file seperti CSV, Excel, XML, JSON dan format berbasis baris. Dengan alat ini Anda dapat menghapus duplikat, menyaring catatan dengan nilai yang hilang, memangkas spasi di depan dan di belakang, mengubah urutan baris ke kolom, mengubah nilai sel, mengelompokkan sel yang serupa, dan melakukan berbagai transformasi lainnya. Untuk memfilter, bergabung, dan transformasi lainnya, kerangka kerja skrip tingkat tinggi seperti Pig bisa sangat berguna. Manfaat menggunakan Pig adalah Anda dapat memproses data dalam jumlah besar dalam mode batch, yang mungkin sulit dilakukan dengan alat mandiri. Ketika Anda tidak yakin tentang transformasi apa yang harus diterapkan dan ingin menjelajahi data dan mencoba transformasi yang berbeda, kerangka kerja kueri interaktif seperti Hive, SparkSQL dapat berguna. Dengan alat ini, Anda dapat membuat kueri data dengan kueri yang ditulis dalam bahasa mirip SQL.

Untuk jenis analisis statistik dasar (dengan analisis seperti jumlah komputasi, maks, min, rata-rata, nilai-N, distinct, korelasi, misalnya), sebagian besar analisis dapat dilakukan menggunakan kerangka kerja Hadoop-MapReduce atau dengan skrip Pig. Baik MapReduce dan Pig memungkinkan analisis data dalam mode batch. Untuk statistik dasar dalam mode batch, kerangka kerja Spark juga merupakan pilihan yang bagus. Untuk statika dasar dalam mode real-time, kerangka kerja Spark Streaming dan Storm dapat digunakan. Untuk statistik dasar dalam mode interaktif, kerangka kerja seperti Hive dan SparkSQL dapat digunakan. Seperti, statistik dasar, kami juga dapat memetakan tipe analisis lain ke salah satu kerangka kerja di Big Data Stack. Gambar 4 dan 5 menunjukkan pemetaan antara berbagai jenis analisis dan kerangka Big Data.

Data Collection		Data Preparation		Basic Statistics	
Analysis Type	Framework (Mode)	Analysis Type	Framework	Analysis Type	Framework (Mode)
Publish-Subscribe	Kafka, Kinesis	Data Cleaning	Open Refine	Counts, Max, Min, Mean, Top-N, Distinct	Hadoop-MapReduce (Batch), Pig (Batch), Spark (Batch), Spark Streaming (Realtime), Spark SQL (Interactive), Hive (Integrative), Storm (Real-time)
Source-Sink	Flume	Data Wrangling	Open Refine DataWrangler	Correlations	Hadoop-MapReduce (Batch), Spark Mlib (Batch)
SQL	Sqoop	De-Duplication	Open Refine, Pig, Hive, Spark SQL		
Queues	SQS, RabbitMQ, ZeroMQ, RESTMQ	Normalization Sampling, Filtering	MapReduce, Pig, Hive, Spark SQL		
Custom Connectors	REST, WebSocket, MQTT				

Clustering		Classification		Regression	
Analysis Type	Framework (Mode)	Analysis Type	Framework (Mode)	Analysis Type	Framework (Mode)
K-Means	Hadoop-MapReduce (Batch), Spark Mlib (Batch & Real-time), H2O (Batch)	KNN	Spark Mlib (Batch, Realtime)	Linear Least Squares	Spark Mlib (Batch, Realtime)
DBSCAN	Spark (Batch)	Decision Trees	Spark Mlib (Batch, Realtime)	Generalized Linear Model	H2O (Batch)
Gaussian Mixture	Spark Mlib (Batch)	Random Forest	Spark Mlib (Batch, Realtime), H2O (Batch)	Stochastic Gradient Descent	Spark Mlib (Batch, Realtime)
PIC	Spark Mlib (Batch)	SVM	Spark Mlib (Batch, Realtime)	Isotonic Regression	Spark Mlib (Batch, Realtime)
LDA	Spark Mlib (Batch)	Naive Bayes	Spark Mlib (Batch, Realtime), H2O (Batch)		
		Deep Learning	H2O (Batch)		

Gambar 4. Arus analisis Mapping untuk Big Data Stack – Part I

Graph Analytics		Time Series Analysis		Dimensionality Reduction		Recommendation	
Analysis Type	Framework (Mode)	Analysis Type	Framework (Mode)	Analysis Type	Framework (Mode)	Analysis Type	Framework (Mode)
Graph Search	Spark GraphX (Batch)	Kalman Filter	Spark (Realtime)	SVD	Spark Mlib (Batch)	Item-bases Recommendation	Spark Mlib (Batch)
Shortest-Path	Spark GraphX (Batch)	Time Frequency Models	Spark (Realtime)	PCA	Spark Mlib (Batch), H2O (Batch)	Collaborative Filtering	Spark Mlib (Batch)
PageRank	Spark GraphX (Batch)	Outlier Detection	Storm (Realtime), Spark (Batch, Realtime)				
Triangle Counting	Spark GraphX (Batch)						
Connected Components	Spark GraphX (Batch)						

Text Analysis		Pattern Mining		Visualization	
Analysis Type	Framework (Mode)	Analysis Type	Framework (Mode)	Analysis Type	Framework (Mode)
Categorization	Hadoop-MapReduce (Batch), Storm (Realtime), Spark (Batch, Realtime)	FP-Growth	Spark Mlib (Batch)	Web Frameworks	Django, Flask
Summarization	Spark (Batch)	Association Rules	Spark Mlib (Batch)	SQL Databases	MySQL
Sentiment Analysis	Storm (Realtime), Spark (Batch, Realtime)	PrefixSpan	Spark Mlib (Batch)	NoSQL Databases	Hbase, DynamoDB, Cassandra, MongoDB
Text Mining	Storm (Realtime), Spark (Batch, Realtime)			Visualization Frameworks	Lightning, pyGal, Seaborn

Gambar 5. Arus analitik Mapping untuk Big Data Stack – Part II

Studi Kasus : Data Analisis Cuaca

Mari kita lihat studi kasus penggunaan Big Data Stack untuk analisis data cuaca. Untuk mendapatkan pilihan alat dan kerangka kerja dari Big Data Stack yang dapat digunakan untuk analisis data cuaca, pertama-tama mari kita buat aliran analisis untuk aplikasi seperti yang ditunjukkan pada Gambar 6.

Koleksi Data

Mari kita asumsikan, kita memiliki beberapa stasiun pemantau cuaca atau titik akhir yang dilengkapi dengan sensor suhu, kelembapan, angin, dan tekanan. Untuk

mengumpulkan dan menyerap data sensor streaming yang dihasilkan oleh stasiun pemantauan cuaca, kita dapat menggunakan framework perpesanan langganan publikasi untuk menyerap data untuk analisis real-time dalam Big Data Stack dan konektor Source-Sink untuk menyerap data ke dalam sistem fie terdistribusi untuk analisis batch

Persiapan Data

Karena data cuaca yang diterima dari stasiun pemantauan yang berbeda dapat memiliki nilai yang hilang, menggunakan unit yang berbeda dan memiliki format yang berbeda, kita mungkin perlu menyiapkan data untuk analisis dengan membersihkan, mengatur, menormalkan, dan memfiter data.

Tipe Analisis

Pilihan jenis analisis didorong oleh persyaratan aplikasi. Katakanlah, kita ingin aplikasi analisis cuaca kita mengumpulkan data pada berbagai skala waktu (menit, jam, harian atau bulanan) untuk menentukan mahasiswa rata-rata, maksimum dan minimum untuk suhu, kelembaban, angin dan tekanan. Kami juga ingin aplikasi mendukung kueri interaktif untuk menjelajahi data, misalnya, kueri seperti: menemukan hari dengan suhu terendah setiap bulan dalam setahun, menemukan 10 hari paling basah teratas dalam setahun, misalnya. Jenis analisis ini termasuk dalam kategori statistik dasar. Selanjutnya kita juga ingin aplikasi membuat prediksi kejadian cuaca tertentu, misalnya memprediksi terjadinya kabut atau kabut asap. Untuk analisis seperti itu, kami membutuhkan model klasifikasi. Selain itu, jika kita ingin memprediksi nilai (seperti jumlah curah hujan), kita memerlukan model regresi.

Mode Analisis

Berdasarkan jenis analisis yang ditentukan pada langkah sebelumnya, diketahui bahwa mode analisis yang diperlukan untuk aplikasi adalah secara batch, real-time dan interaktif.

Visualisasi

Aplikasi front end untuk memvisualisasikan hasil analisis akan bersifat dinamis dan interaktif.


Alur Analisis Pemetaan ke Big Data Stack

Sekarang setelah kita memiliki aliran analisis untuk aplikasi, mari kita mapkan pilihan pada setiap langkah aliran ke Big Data Stack. Gambar 6 menunjukkan subset dari komponen Big Data Stack. berdasarkan aliran analisis. Untuk mengumpulkan dan mencerna data sensor streaming yang dihasilkan oleh stasiun pemantauan cuaca, kita


dapat menggunakan kerangka perpesanan langganan-publikasi seperti Apache Kafka (untuk analisis real-time dalam Big Data Stack). Setiap stasiun cuaca mempublikasikan data sensor ke Kafka. Kerangka kerja analisis real-time seperti Storm dan Spark Streaming dapat menerima data dari Kafka untuk diproses. Untuk analisis batch, kita dapat menggunakan konektor sumber-sink seperti Flume untuk memindahkan data ke HDFS. Setelah data ada di HDFS, kita dapat menggunakan kerangka kerja pemrosesan batch seperti Hadoop-MapReduce. Kita juga dapat menggunakan Spark untuk transformasi Map dan Reduce tersebut.

Meskipun kerangka kerja pemrosesan batch dan real-time berguna saat tujuan dan persyaratan analisis diketahui sebelumnya, alat kueri interaktif dapat berguna untuk menjelajahi data. Kita bisa menggunakan kerangka kerja kueri interaktif seperti Spark SQL, yang bisa membuat kueri data dalam HDFS untuk kueri interaktif. Untuk menyajikan hasil analisis batch dan real-time, database NoSQL seperti DynamoDB dapat digunakan sebagai database penyajian.

Untuk mengembangkan aplikasi web dan menampilkan hasil analisis kita dapat menggunakan kerangka kerja web seperti Django.



Gambar 6. Arus analisis untuk Aplikasi data analisis cuaca



Gambar 7. Penggunaan Big Data Stack untuk analisis data cuaca



**BIG
DATA**